

Simulação de Rede Distribuída para Inferência de IA com Avaliação de Confiabilidade baseada em Reputação

Allan Mateus de Souza Arruda¹, Lara Andrade Carvalho¹

¹Curso de Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

{allan.arruda, lara.carvalho}@sga.pucminas.br

Abstract. *The execution of Artificial Intelligence (AI) tasks has migrated to decentralized architectures to rationalize computational resources. However, distributed networks operate in uncontrolled environments, where unstable or malicious nodes can corrupt aggregated results (Byzantine Attacks). To mitigate this problem without depending on computationally costly consensus mechanisms, this work analyzes the impact of reputation mechanisms on the reliability of distributed AI inference. Through a quantitative experimental research, a simulator built with Docker containers and large language models (LLMs), executed locally through the Ollama platform, is proposed. As a first stage, a functional simulator was implemented, integrating containerized nodes, an asynchronous orchestrator, behavioral profiles (honest, malicious, and unstable), reputation-weighted consensus, and metrics collection. Preliminary runs in simulation mode show that reputation-weighted consensus preserves 95% accuracy under a 50% colluding-adversary scenario, where simple majority voting drops to 0%. Systematic evaluation with local LLM inference is planned for the next stages.*

Resumo. *A execução de tarefas de Inteligência Artificial (IA) tem migrado para arquiteturas descentralizadas visando a racionalização de recursos computacionais. Contudo, redes distribuídas operam em ambientes não controlados, onde nós instáveis ou maliciosos podem corromper os resultados agregados (Ataques Bizantinos). Para mitigar esse problema sem depender de mecanismos de consenso computacionalmente custosos, este trabalho analisa o impacto de mecanismos de reputação na confiabilidade da inferência distribuída de IA. Por meio de uma pesquisa experimental quantitativa, propõe-se um simulador construído com containers Docker e modelos de linguagem de grande escala (LLMs), executados localmente por meio da plataforma Ollama. Como primeira etapa, implementou-se um simulador funcional que integra nós containerizados, orquestrador assíncrono, perfis comportamentais (honesto, malicioso e instável), consenso ponderado por reputação e coleta de métricas. Execuções preliminares em modo de simulação mostram que o consenso ponderado por reputação preserva 95% de acurácia em um cenário com 50% de adversários em conluio, no qual o voto por maioria simples cai para 0%. A avaliação sistemática com inferência local de LLMs está prevista para as etapas seguintes.*

Bacharelado em Engenharia de Software - PUC Minas
Trabalho de Conclusão de Curso (TCC)

Orientadora do TCC II: Isabela Borlido Barcelos

Belo Horizonte, 30 de agosto de 2026.

1. Introdução

A demanda por processamento de tarefas de Inteligência Artificial (IA) cresce de forma contínua, o que exige infraestruturas computacionais robustas e escaláveis. Tradicionalmente, grande parte dessa execução ocorre em ambientes centralizados, como servidores e *data centers*, gerando alto custo por requisição e criando pontos únicos de falha. Diante disso, observa-se uma mudança de paradigma em direção a arquiteturas descentralizadas, que distribuem o poder computacional entre múltiplos nós e reduzem a dependência de provedores centrais. A adoção de *Edge Computing* (computação de borda) e de redes distribuídas permite a inferência de IA de forma particionada ou replicada, o que racionaliza os recursos computacionais disponíveis [Shi et al. 2016, Tanenbaum and van Steen 2017, Coulouris et al. 2021]. O estudo dessas infraestruturas é fundamental para o avanço das tecnologias de IA descentralizada, visto que tais redes operam em ambientes não controlados. Pesquisas recentes sobre IA distribuída e compartilhamento descentralizado de modelos evidenciam a necessidade de avaliar protocolos de segurança, confiança e coordenação nesses ecossistemas [Wei and Liu 2024, Blockchain-based AI 2024].

Em redes distribuídas de inferência de IA, os participantes (nós) operam de forma independente, o que introduz desafios significativos de confiabilidade, tolerância a falhas e coordenação arquitetural. Como os nós não estão sob uma autoridade central, eles podem retornar respostas incorretas por diferentes motivos: falhas técnicas transitórias, indisponibilidade momentânea ou ações intencionalmente adversariais. Esse último caso caracteriza as chamadas Falhas (ou Ataques) Bizantinas, formalizadas por Lamport et al. [Lamport et al. 1982], nas quais um subconjunto de participantes envia informações propositalmente inconsistentes para corromper a decisão coletiva. A literatura clássica de sistemas distribuídos demonstra que garantir consistência sob esse tipo de falha é um problema não trivial e que mecanismos de tolerância podem ser computacionalmente custosos [Castro and Liskov 1999, Tanenbaum and van Steen 2017]. No contexto da Engenharia de Software, enfrentar esse problema envolve três desafios concretos: definir uma arquitetura distribuída adequada, construir um simulador reproduzível que reproduza comportamentos adversariais controlados e avaliar experimentalmente como a rede se degrada sob diferentes intensidades de ataque. Nesse contexto, este trabalho propõe a investigação do seguinte problema de pesquisa: **como mecanismos de reputação podem mitigar o impacto de agentes maliciosos na confiabilidade de uma rede distribuída de inferência de IA?**. A resposta a essa questão exige a análise do impacto de agentes com comportamentos erráticos sobre o consenso da rede.

A resolução desse problema possui relevância científica e tecnológica, especialmente na Engenharia de Software voltada à confiabilidade e à observabilidade de sistemas distribuídos. A adoção de *Edge Computing* e de dispositivos da Internet das Coisas (IoT, do inglês *Internet of Things*) exige mecanismos que preservem a integridade dos resultados em ambientes potencialmente adversariais [Shi et al. 2016]. Optou-se por investi-

gar reputação como mecanismo de confiança porque ela permite atribuir pesos distintos aos nós com base em seu histórico de comportamento, sem exigir uma infraestrutura de consenso criptográfico completa [Kamvar et al. 2003, Chen et al. 2024]. Essa decisão decorre do objetivo do TCC, que é avaliar experimentalmente a influência de agentes maliciosos em um simulador controlado, e não implementar uma rede produtiva de *blockchain*.

A viabilidade experimental dessa investigação depende de um ambiente que seja, ao mesmo tempo, isolado, reproduzível e controlável. Por isso, este trabalho adota a containerização com Docker como base da simulação. O uso de *containers* é relevante porque permite representar cada nó como um processo isolado, com estado, porta e comportamento próprios, garantindo reprodutibilidade dos cenários e evitando interferências entre participantes [Docker Inc. 2026, Burns et al. 2022]. Além disso, a containerização reduz o custo de execução em comparação a uma infraestrutura física distribuída e possibilita variar sistematicamente a escala da rede e a proporção de agentes maliciosos, condições difíceis de reproduzir em ambientes reais. Assim, o Docker atua como o principal habilitador metodológico do experimento proposto.

Para responder à questão de pesquisa levantada, estabelece-se que **o objetivo geral deste trabalho é analisar o impacto de mecanismos de reputação na confiabilidade de redes distribuídas de inferência de IA por meio de simulação experimental quantitativa**. Para o alcance desse propósito, definem-se os seguintes objetivos específicos: (i) construir um ambiente de simulação utilizando *containers* Docker para isolar e replicar o comportamento de múltiplos nós executando modelos de linguagem de grande escala (LLMs), executados localmente por meio da plataforma Ollama; (ii) implementar diferentes perfis comportamentais para os participantes, representando nós honestos, maliciosos e instáveis; e (iii) comparar a acurácia de um modelo de consenso ponderado por reputação com mecanismos de consenso simples sob diferentes intensidades de ataque.

Ao concluir a execução metodológica proposta, espera-se obter um diagnóstico quantitativo sobre a viabilidade de sistemas de reputação dinâmicos para a IA descentralizada. A partir da simulação de múltiplos cenários de rede, variando a escala de nós (5, 10 e 20) e a presença de agentes maliciosos (0%, 25% e 50%), projeta-se coletar métricas empíricas de desempenho, acurácia e comportamento dos participantes. Espera-se avaliar se o consenso ponderado por reputação pode reduzir a influência de agentes nocivos progressivamente, mantendo a taxa de acerto do sistema distribuído em patamar superior ao de abordagens desprovidas de verificação de confiança. Os resultados serão analisados dentro do escopo definido para o simulador, considerando as limitações de um ambiente local e containerizado.

O restante deste documento está organizado da seguinte forma. A Seção 2 apresenta a fundamentação teórica que embasa esta pesquisa. A Seção 3 detalha os trabalhos relacionados. A Seção 4 apresenta os materiais e métodos adotados para o experimento. A Seção 5 apresenta os resultados preliminares obtidos até o momento.

2. Fundamentação Teórica

A infraestrutura para a execução de tarefas de Inteligência Artificial (IA) tem passado por uma mudança estrutural, migrando de ambientes centralizados em *data centers* para arquiteturas distribuídas [Russell and Norvig 2020]. Esse movimento é im-

pulsionado pela computação em borda (*edge computing*), uma abordagem que processa os dados próximos à fonte geradora [Shi et al. 2016]. No escopo dos sistemas distribuídos, a computação em borda permite mitigar problemas de latência e de largura de banda que comumente afetam as soluções em nuvem (*cloud computing*) [Tanenbaum and van Steen 2017, Coulouris et al. 2021]. Neste TCC, esse conceito fundamenta a decisão de representar uma rede de inferência por nós independentes, executados em ambiente local, para observar como a arquitetura se comporta quando parte dos participantes retorna respostas incorretas ou deixa de responder.

2.1. Inteligência Artificial Distribuída

A Inteligência Artificial Distribuída envolve a execução ou coordenação de tarefas inteligentes por múltiplos nós, agentes ou dispositivos. Em vez de concentrar todo o processamento em uma única infraestrutura central, esse paradigma permite que diferentes participantes colaborem na execução de inferências, no compartilhamento de modelos ou no treinamento colaborativo. Essa organização favorece escalabilidade, redução de dependência de provedores centrais e melhor aproveitamento dos recursos computacionais disponíveis na borda da rede [Wei and Liu 2024, Wang et al. 2025]. No presente trabalho, esse conceito é aplicado à inferência redundante: a mesma tarefa será encaminhada a múltiplos nós simulados, e a resposta final será obtida por consenso. A escolha por inferência redundante foi feita porque ela permite avaliar confiabilidade e comportamento adversarial sem exigir particionamento interno dos modelos de IA.

A operação de redes descentralizadas em ambientes não controlados introduz riscos significativos relacionados à integridade das respostas geradas. Em redes organizadas sob o modelo par-a-par (*peer-to-peer* - P2P), os nós participantes possuem autonomia e podem apresentar comportamentos imprevisíveis. Falhas técnicas, instabilidades temporárias de conexão ou ações intencionalmente maliciosas comprometem a confiabilidade do resultado global do sistema. Esse fenômeno é comumente descrito na literatura como Falhas Bizantinas, nas quais agentes adversariais transmitem informações propositalmente erradas para corromper o sistema [Lamport et al. 1982, Castro and Liskov 1999]. No escopo deste TCC, as Falhas Bizantinas serão representadas por nós maliciosos simulados, configurados para retornar respostas divergentes do valor esperado. Essa modelagem permite avaliar experimentalmente o impacto desses participantes no consenso da rede, sem afirmar que o simulador reproduz toda a complexidade de uma rede distribuída real.

Para assegurar a coordenação e a consistência dos dados em sistemas distribuídos, empregam-se protocolos de consenso, que alinham o estado da rede entre os participantes [Tanenbaum and van Steen 2017, Coulouris et al. 2021]. Redes descentralizadas podem utilizar soluções baseadas em registros distribuídos, incluindo abordagens inspiradas em *blockchain* para compartilhamento confiável de modelos de IA [Blockchain-based AI 2024]. Contudo, esta pesquisa não implementa uma *blockchain* real; seu foco está em avaliar um mecanismo leve de consenso ponderado por reputação. Durante a definição da solução, optou-se por não implementar *blockchain* porque o objetivo central não é estudar armazenamento imutável, mineração, validação criptográfica ou contratos inteligentes, mas sim medir como pesos de confiança afetam a resposta agregada em uma rede simulada.

2.2. Sistemas de Reputação em Redes Distribuídas

Os sistemas de reputação surgem como uma alternativa adaptativa para gerenciar a colaboração em infraestruturas descentralizadas. Esses sistemas registram o histórico de comportamento dos nós e atribuem pesos diferentes às suas contribuições, de modo que participantes confiáveis passem a exercer maior influência nas decisões coletivas, enquanto nós instáveis ou maliciosos tenham sua participação reduzida. O algoritmo *Eigen-Trust* é uma base clássica para reputação em redes P2P, pois propõe o cálculo de confiança global a partir de interações locais entre participantes [Kamvar et al. 2003]. Em ambientes recentes de IA distribuída e aprendizado federado, mecanismos de reputação também são empregados para mitigar contribuições maliciosas e aumentar a confiabilidade do processo colaborativo [Chen et al. 2024]. No modelo adotado neste TCC, a reputação será usada diretamente no consenso: respostas de nós com melhor histórico terão maior peso, enquanto respostas de nós divergentes terão influência reduzida ao longo das rodadas. Essa decisão foi tomada porque a reputação permite avaliar confiança de forma incremental e mensurável dentro do simulador.

3. Trabalhos Relacionados

Esta seção apresenta os principais trabalhos que fundamentam a proposta. A discussão está organizada em quatro eixos temáticos: (i) confiança e governança em IA distribuída; (ii) aprendizado federado e reputação aplicada ao treinamento; (iii) gestão de confiança em redes P2P; e (iv) tolerância a falhas bizantinas e containerização de ambientes experimentais. Para cada trabalho, descrevem-se a contribuição, a limitação em relação ao escopo deste TCC e a forma como ele fundamenta ou é complementado pela proposta.

O trabalho de Wei e Liu [Wei and Liu 2024] sistematiza requisitos de robustez, privacidade e governança em sistemas de IA distribuída, propondo um arcabouço conceitual para caracterizar ameaças e propriedades desejáveis nesses ambientes. Sua contribuição está em demonstrar que a confiança não pode ser tratada apenas como atributo do modelo de IA, mas também como propriedade da arquitetura que coordena os participantes, o que reforça a pertinência de investigar mecanismos de confiança em nível arquitetural. A limitação, para o escopo deste TCC, é o caráter amplo e predominantemente conceitual da discussão, que não define um procedimento experimental replicável para medir confiabilidade. O presente trabalho apropria-se dessa visão arquitetural, porém a operacionaliza: transforma a preocupação com confiança em um experimento mensurável, no qual a confiabilidade é observada a partir de respostas de nós simulados e de um consenso ponderado por reputação.

No eixo do aprendizado federado, os trabalhos de McMahan et al. [McMahan et al. 2017], Bonawitz et al. [Bonawitz et al. 2019] e Kairouz et al. [Kairouz et al. 2021] consolidaram estratégias para o treinamento colaborativo de modelos a partir de dados descentralizados, evitando a transferência direta dos conjuntos locais. Suas contribuições incluem a formalização do protocolo de agregação de parâmetros, a descrição de arquiteturas de larga escala e o mapeamento de desafios abertos, como custos de comunicação, heterogeneidade de dados e disponibilidade variável dos nós. A limitação em relação a este estudo é que o foco recai sobre a fase de *treinamento* de modelos, e não sobre a inferência redundante de respostas. Este TCC reaproveita essas premissas arquiteturais — coordenação entre participantes autônomos e agregação de

contribuições — mas desloca a análise para a fase de inferência, na qual múltiplos nós respondem à mesma tarefa e o sistema calcula um resultado agregado comparável a um referencial exato.

Ainda no contexto federado, Chen et al. [Chen et al. 2024] investigam a aplicação de reputação para mitigar atualizações maliciosas em aprendizado federado assíncrono associado a *blockchain*. A contribuição desse trabalho está em demonstrar empiricamente que o histórico de comportamento dos participantes pode e deve influenciar o peso de suas contribuições, aumentando a robustez do processo colaborativo diante de agentes adversariais. Sua limitação, para esta pesquisa, é o vínculo com a etapa de treinamento e atualização de parâmetros de modelos. O trabalho aqui proposto complementa essa abordagem ao transportar a ideia de ponderação por reputação para a etapa de inferência: em vez de ponderar atualizações de parâmetros, ponderam-se respostas retornadas por nós simulados, o que permite medir diretamente acurácia e impacto de agentes maliciosos em rodadas controladas.

A gestão de confiança em redes P2P possui base clássica no algoritmo *EigenTrust* [Kamvar et al. 2003], cuja contribuição é propor a construção de uma medida de reputação global a partir de interações locais entre pares, mitigando a influência de nós que distribuem conteúdo inautêntico. A limitação, no contexto deste TCC, é que o algoritmo foi concebido para compartilhamento de arquivos em redes P2P, não tendo sido projetado para tarefas de IA generativa ou para inferência com LLMs, nas quais a noção de “resposta correta” exige comparação semântica. A contribuição deste trabalho é adaptar o princípio de reputação derivada de interações — em particular a noção de centralidade sobre a matriz de concordância — para uma rede simulada de inferência, na qual a pontuação de cada nó será atualizada conforme a proximidade entre suas respostas e o *Ground Truth*.

No eixo de infraestrutura experimental, a literatura e a prática de Engenharia de Software adotam a containerização como forma de emular redes distribuídas em ambiente controlado, pois *containers* permitem isolar processos, dependências e configurações de execução [Docker Inc. 2026, Burns et al. 2022]. A contribuição dessas referências está em fornecer os fundamentos de isolamento e reprodutibilidade que sustentam experimentos rastreáveis. A limitação é que a containerização não substitui uma implantação em rede real com latência física, falhas de hardware e heterogeneidade plena. A presente pesquisa assume explicitamente essa limitação e adota Docker justamente pela reprodutibilidade: cada *container* representará um nó com perfil comportamental definido pelos autores, viabilizando a repetição idêntica dos cenários.

Por fim, a mitigação de Falhas Bizantinas é um problema clássico em sistemas distribuídos [Lamport et al. 1982, Castro and Liskov 1999]. A contribuição desses trabalhos está na formulação teórica do problema de consenso sob falhas arbitrárias e na demonstração de protocolos capazes de tolerar um número limitado de participantes maliciosos. A limitação, em relação a este estudo, é que tais formulações não tratam de redes de inferência com modelos de linguagem executados localmente, nem de respostas de natureza textual/semântica. O presente estudo aplica essa discussão a um contexto novo — a inferência distribuída de IA generativa — submetendo a rede simulada a condições de estresse com proporções de até 50% de nós maliciosos.

Em síntese, enquanto parte da literatura discute confiança em IA distribuída de forma ampla e outra parte aplica reputação ao treinamento federado, observa-se uma lacuna empírica quanto ao uso de simuladores locais em Docker para testar a confiabilidade da inferência direta de IA Generativa. O sistema proposto neste trabalho integra isolamento por *containers*, perfis comportamentais controlados e votação baseada em reputação para permitir uma avaliação quantitativa rastreável, focada em decisões de arquitetura e tolerância a falhas no campo da Engenharia de Software.

4. Materiais e Métodos

A metodologia adotada para a consecução dos objetivos deste estudo caracteriza-se como uma pesquisa experimental quantitativa. Esse tipo de pesquisa baseia-se na formulação de experimentos controlados e reproduzíveis, permitindo a observação metódica de variáveis independentes (tamanho da rede e percentual de agentes maliciosos) sobre uma variável dependente (acurácia do consenso). Optou-se por simulação em ambiente local porque ela permitirá controlar a quantidade de nós, os perfis de comportamento e as condições de ataque sem depender de uma infraestrutura física distribuída, tornando o experimento mais rastreável e adequado ao escopo de um TCC, embora limite a generalização dos resultados para redes reais. A Figura 1 apresenta uma visão de alto nível das etapas metodológicas propostas, que serão detalhadas nas subseções seguintes.




Figura 1. Visão geral de alto nível das etapas metodológicas propostas.

4.1. Ambiente de Simulação e Ferramentas

O ambiente de simulação será construído com base em tecnologias de containerização e execução local de modelos de IA, seguindo a premissa de isolamento de processos e reprodutibilidade de ambientes computacionais [Docker Inc. 2026, Burns et al. 2022]. Adotar-se-á o Docker porque cada *container* poderá representar um nó independente da rede, com portas, estado e comportamento próprios, facilitando a reprodução dos cenários experimentais. Será utilizada a linguagem de programação Python para o desenvolvimento do coordenador (orquestrador) da simulação, escolha justificada por sua facilidade de integração com APIs HTTP, execução assíncrona, registro de *logs* e posterior análise estatística dos resultados. Em cada *container*, a inferência textual será processada por modelos de linguagem de grande escala (LLMs) executados localmente por meio da plataforma Ollama. No escopo deste TCC, adotar-se-á a execução local para evitar dependência de APIs externas, reduzir variações de custo por requisição e manter maior controle sobre as condições do experimento.

4.2. Arquitetura e Componentes do Simulador

O simulador proposto será organizado em torno de um componente orquestrador e de nós simulados isolados, com clara separação de responsabilidades entre coordenação, inferência, consenso, reputação e coleta de métricas. Cada nó da rede será representado por

um *container* Docker independente, o que oferecerá isolamento de estado e permitirá reproduzir restrições de comunicação de uma rede par-a-par (P2P) lógica. A implementação será dividida nos seguintes módulos:

- **Orquestrador:** controlará os experimentos, distribuirá as tarefas de inferência aos nós e coletará de forma assíncrona as respostas geradas.
- **Nós simulados:** processarão as tarefas recebidas e retornarão respostas ao orquestrador segundo o perfil comportamental atribuído (honesto, instável ou malicioso).
- **Módulo de consenso:** calculará a resposta final da rede por meio do consenso ponderado por reputação.
- **Módulo de reputação:** manterá e atualizará o histórico de confiabilidade dos nós ao longo das rodadas.
- **Coletor de métricas:** registrará acurácia, latência, respostas individuais, a reputação antes e depois de cada rodada e o comportamento dos participantes.

A estratégia de inferência adotada será redundante: a mesma tarefa será enviada para múltiplos nós por meio do orquestrador e, após o processamento, as respostas serão encaminhadas ao módulo de consenso, que calculará o resultado agregado com base na reputação de cada nó. Essa abordagem foi escolhida por ser mais adequada ao escopo do Trabalho de Conclusão de Curso, pois permitirá avaliar confiabilidade, reputação e comportamento malicioso sem exigir a fragmentação interna de modelos de IA, como ocorre em estratégias de paralelismo por camadas ou por tensores. A divisão modular será adotada para facilitar a validação individual de cada etapa e permitir rastrear a origem de eventuais divergências nos resultados.

4.3. Definição das Tarefas, Prompts e *Ground Truth*

As tarefas de inferência serão preferencialmente objetivas e verificáveis, como perguntas factuais, operações aritméticas simples e classificações com resposta esperada previamente definida. Essa escolha foi tomada porque o objetivo do experimento não será avaliar criatividade textual ou qualidade subjetiva de respostas, mas medir a confiabilidade de um consenso distribuído diante de nós honestos, instáveis e maliciosos. Ao utilizar tarefas com resposta esperada, tornar-se-á possível comparar diretamente o resultado agregado com o *Ground Truth*.

O *Ground Truth* será definido antes da execução das rodadas, a partir de respostas esperadas registradas no conjunto de tarefas do experimento. Dessa forma, cada tarefa enviada aos nós terá um valor de referência associado, permitindo calcular acurácia, identificar divergências e atualizar a reputação dos participantes de forma rastreável. Para padronizar as respostas dos nós honestos e reduzir variações irrelevantes, cada *container* receberá um *prompt* de sistema com instruções de objetividade, conforme o esboço apresentado a seguir:

```
1 PROMPT_SISTEMA = ""
2 Voce e um no de inferencia em uma rede distribuida.
3 Responda a pergunta a seguir de forma objetiva, retornando
4 SOMENTE a resposta final, sem explicacoes, comentarios
5 ou formatacao adicional.
6
7 Pergunta: {tarefa}
```

8 Resposta:

9 """

Listing 1. Esboço do *prompt* de sistema enviado aos nós de inferência.

O comportamento adversarial não será obtido alterando o *prompt* de conteúdo, mas sim por meio de uma camada de injeção controlada no invólucro de cada nó, garantindo que a manipulação seja determinística e rastreável. Os nós honestos retornarão a resposta produzida pelo modelo; os nós maliciosos aplicarão uma função de corrupção à resposta (por exemplo, substituição por um valor incorreto plausível ou inversão da classe esperada); e os nós instáveis não retornarão resposta dentro do tempo limite (*time-out*). Exemplos de tarefas incluem perguntas factuais (“Qual é a capital do Brasil?” → Brasília), operações aritméticas (“Quanto é $128 + 256$?” → 384) e classificações (“Classifique como Positivo ou Negativo” → rótulo esperado), cada uma com *Ground Truth* previamente registrado.

Nas tarefas de resposta discreta, a acurácia será registrada como acerto ou erro binário do resultado agregado. Para tarefas de natureza generativa, nas quais há variação textual não-discreta, o protocolo de equivalência utilizará a métrica de Similaridade de Cosseno (*Cosine Similarity*) sobre *embeddings* textuais, considerando equivalente ao *Ground Truth* qualquer resposta cujo índice de similaridade seja igual ou superior a 0,85. Esse limiar permitirá aceitar variações semânticas válidas (por exemplo, “Brasília” e “a cidade de Brasília”) sem comprometer o rigor da avaliação.

4.4. Fluxo de Execução da Inferência

O fluxo de execução iniciará com o envio de uma tarefa pelo orquestrador. Essa tarefa será replicada e enviada para múltiplos nós simulados, que poderão apresentar comportamento honesto, instável ou malicioso. Cada nó processará a tarefa de forma independente e retornará uma resposta ao orquestrador por meio da interface de comunicação definida no simulador. Após a coleta assíncrona das respostas, o módulo de consenso aplicará o cálculo ponderado por reputação para determinar o resultado agregado da rede.

Em seguida, o resultado obtido será comparado com o *Ground Truth*, permitindo calcular a acurácia da rede. A reputação de cada nó será então atualizada com base em seu comportamento na rodada: nós que retornarem respostas próximas ao resultado esperado tenderão a ganhar reputação, enquanto nós divergentes, instáveis ou maliciosos sofrerão penalização. Essa atualização não terá finalidade de certificação de segurança; ela permitirá avaliar experimentalmente se a reputação reduz a influência de respostas inadequadas ao longo das rodadas.

4.5. Estratégia Experimental e Definição de Perfis

O experimento consolidar-se-á em nove cenários de teste distintos, gerados pela combinação de duas variáveis de controle. A primeira variável será a escala da rede, que assumirá configurações de 5, 10 e 20 nós simulados, permitindo observar como a variação da quantidade de participantes afeta a dinâmica coletiva do sistema [Barabási 2016]. A escolha por 5 nós representa um cenário mínimo para observar consenso; 10 nós representam uma rede intermediária, ainda viável para execução local; e 20 nós permitem testar uma condição de maior escala dentro dos recursos disponíveis para o TCC. A segunda variável será a taxa de presença de agentes maliciosos, estipulada em 0%, 25% e 50%:

a taxa de 0% funcionará como linha de base, 25% representará um cenário adversarial moderado e 50% permitirá observar o comportamento do consenso em condição severa de contaminação das respostas. Para operacionalizar essa manipulação de variáveis, o sistema injetará comportamentos predefinidos nos nós por meio do *script* orquestrador.

Os nós serão categorizados em três perfis comportamentais: nós honestos (que tenderão a retornar a resposta esperada), nós maliciosos (que aplicarão ruído ou respostas deliberadamente incorretas) e nós instáveis (que falharão em responder dentro do tempo estipulado). Cada rodada abrangerá o envio simultâneo das tarefas, o processamento paralelo nos *containers*, a coleta assíncrona das respostas, o processamento do consenso, a comparação com o *Ground Truth* e o registro dos dados. Cada uma das nove combinações será executada em múltiplas rodadas independentes, de forma a permitir a análise estatística da variação de acurácia e da evolução da reputação ao longo do tempo.

4.6. Avaliação Experimental e Métricas

Esta subseção unifica os critérios de avaliação do simulador, apresentando (i) a formalização do consenso e da reputação, (ii) o alinhamento entre objetivos e métricas por meio do modelo *Goal Question Metric* (GQM) e (iii) a definição operacional das métricas coletadas.

A métrica principal será a acurácia obtida após o consenso. O sistema implementará um motor de reputação que atualizará periodicamente o índice de confiabilidade de cada *container* com base na proximidade entre suas respostas e o *Ground Truth*. O resultado agregado da rede será calculado pela Equação 1, que define o Consenso Ponderado, no qual cada voto será ponderado não apenas pela reputação do nó, mas também por sua centralidade na rede:

$$ConsensoPonderado = \frac{\sum Voto_i \cdot Reputação_i \cdot C_i}{\sum Reputação_i \cdot C_i} \quad (1)$$

O fator C_i representará a centralidade de autovetor (*eigenvector centrality*) do nó i , métrica que quantifica a influência relativa de um participante a partir de suas conexões com outros nós igualmente influentes [Barabási 2016, Kamvar et al. 2003]. A centralidade será obtida pela Equação 2, na qual A é a matriz de concordância entre os nós, λ_{max} é o maior autovalor associado e C_i corresponde à i -ésima componente do autovetor principal, normalizado no intervalo $[0, 1]$:

$$A \cdot c = \lambda_{max} \cdot c \implies C_i = \frac{1}{\lambda_{max}} \sum_j A_{ij} C_j \quad (2)$$

A reputação de cada nó (R_i) será atualizada ao final de cada rodada utilizando um fator de decaimento (α), permitindo que o sistema valorize o comportamento recente sem desconsiderar o histórico, conforme a Equação 3:

$$R_i^{(t+1)} = \alpha \cdot R_i^{(t)} + (1 - \alpha) \cdot S_i^{(t)} \cdot \hat{C}_i^{(t)} \quad (3)$$

Onde $R_i^{(t)}$ será a reputação atual do nó i , α será o fator de inércia (definido empiricamente como 0,8 para o experimento), $S_i^{(t)}$ será a pontuação obtida na rodada t (1 para

resposta equivalente ao *Ground Truth*, 0 para divergente e -1 para ausência de resposta) e $\hat{C}_i^{(t)}$ será a centralidade normalizada do nó i no intervalo $[0, 1]$, utilizada como fator de ajuste para que a influência de cada nó module a atualização de sua reputação.

Para garantir que os experimentos estejam alinhados aos objetivos do trabalho, será utilizada a abordagem *Goal Question Metric* (GQM), proposta por Basili et al. Essa abordagem permitirá definir objetivos de avaliação, derivar questões que os representem e identificar métricas capazes de respondê-las, estruturando a verificação da efetividade do mecanismo de reputação na redução da influência de nós maliciosos e no aumento da confiabilidade da rede. A Tabela 1 apresenta os objetivos, questões e métricas definidos, e a Tabela 2 detalha a definição operacional de cada métrica.

Tabela 1. Modelo GQM utilizado no trabalho.

Objetivo	Questão	Métrica
Avaliar a confiabilidade da rede	O mecanismo de reputação melhora a qualidade das respostas produzidas pela rede?	Acurácia do Consenso
		Precisão do Consenso
Avaliar resistência a nós maliciosos	A reputação reduz a influência de participantes maliciosos?	Taxa de Detecção de Nós Maliciosos
		Centralidade de Reputação
Avaliar desempenho da solução	Qual o impacto do consenso no tempo de resposta da rede?	Latência Média
		Disponibilidade
Avaliar efetividade da reputação	A reputação reflete corretamente o comportamento histórico dos nós?	Evolução da Reputação
		Acurácia do Consenso

As métricas foram definidas com base nos objetivos do trabalho e serão coletadas durante a execução dos experimentos. Para cada cenário, elas permitirão comparar o comportamento da rede sob diferentes níveis de participação maliciosa. Os resultados serão posteriormente consolidados em gráficos e tabelas, possibilitando comparar o desempenho da rede em cenários com diferentes quantidades de nós e diferentes percentuais de participantes maliciosos. Secundariamente, serão registradas métricas de tempo de resposta, taxa de falha e comportamento por perfil de nó.

4.7. Rastreabilidade dos Experimentos

Para garantir rastreabilidade, cada execução do simulador registrará um conjunto mínimo de informações em *logs* estruturados. Serão armazenados o identificador da rodada, a quantidade de nós, o percentual de nós maliciosos, o perfil atribuído a cada nó, a resposta individual de cada participante, a reputação antes e depois da rodada, o resultado obtido pelo consenso, o *Ground Truth*, a acurácia calculada e o tempo de resposta. Essa decisão foi tomada porque a análise experimental dependerá de evidências reproduzíveis: os registros permitirão auditar por que determinado consenso foi produzido, identificar quais

Tabela 2. Definição operacional das métricas de avaliação do simulador.

Métrica	Descrição
Acurácia do Consenso	Percentual de respostas corretas produzidas pela rede em relação ao <i>Ground Truth</i> definido para cada tarefa.
Latência Média	Tempo médio necessário para obtenção do resultado final após a execução do consenso.
Taxa de Detecção de Nós Maliciosos	Percentual de nós maliciosos corretamente identificados pelo sistema de reputação.
Disponibilidade	Percentual de tarefas concluídas com sucesso em relação ao total de tarefas executadas.
Precisão do Consenso	Grau de concordância entre o resultado produzido pelo consenso e o resultado esperado.
Evolução da Reputação	Variação da reputação dos nós ao longo das execuções experimentais.
Centralidade de Reputação	Mede a influência relativa de um nó na rede simulada (baseada em métricas de autovetor/ <i>eigenvector</i>), permitindo identificar se a confiança no consenso está concentrada em poucos nós ou distribuída de forma mais homogênea.

nós influenciaram o resultado e comparar o desempenho entre cenários com diferentes escalas e proporções de agentes maliciosos.

4.8. Limitações do Estudo

Este estudo possui algumas limitações. Primeiramente, os experimentos serão realizados em ambiente local e containerizado, o que permitirá controlar melhor as variáveis do experimento, mas não reproduzirá integralmente todas as condições de uma rede distribuída real. Além disso, a estratégia adotada será baseada em inferência redundante, na qual a mesma tarefa é enviada para múltiplos nós, não sendo abordadas técnicas mais complexas de particionamento de modelos, como paralelismo por camadas ou por tensores. Outra limitação está relacionada ao uso de modelos de linguagem executados localmente, que podem apresentar variações de desempenho conforme os recursos computacionais disponíveis na máquina hospedeira. Dessa forma, os resultados obtidos deverão ser interpretados considerando o escopo experimental definido para este trabalho.

5. Resultados Preliminares

Esta seção reporta os resultados iniciais do trabalho, concentrados no desenvolvimento do software e na coleta preliminar de dados. Até o momento, foi construída e validada a primeira versão funcional do simulador descrito na Seção 4, cobrindo a distribuição de tarefas, a coleta assíncrona de respostas, o consenso ponderado por reputação, a atualização de reputação e o registro de métricas. A execução com inferência real via LLMs e a análise estatística com repetições independentes constituem as próximas etapas do trabalho.

O repositório do projeto contém o orquestrador central (coleta concorrente das respostas via `httpx` e `asyncio.gather`, em topologia estrela), o servidor de cada nó em contêiner (FastAPI, com as rotas `/health` e `/infer`) e os módulos de reputação, consenso, perfis comportamentais, carregamento de tarefas, extração da resposta numérica e coleta de métricas, além dos `Dockerfile`, do `docker-compose.yml` e de um gerador de composição para N nós. Cada nó opera em dois modos, selecionados por variável de ambiente: `mock` (comportamento do perfil fabricado, para validar comunicação e reputação sem modelo) e `model` (inferência real com um LLM causal, tendo o `SmolLM3-3B` como modelo padrão). O conjunto de dados adotado é o `GSM8K` [Cobbe et al. 2021], com a resposta final extraída segundo a convenção do marcador `####`. O *prompt* efetivamente implementado para os nós de inferência é apresentado na Listagem 2. A versão atual implementa a atualização de reputação por média móvel exponencial e o consenso ponderado diretamente pela reputação dos nós; o fator de centralidade C_i das Equações 1–3, o protocolo de similaridade de cosseno e a consolidação da inferência real serão incorporados na etapa seguinte.

```
1 _PROMPT_TEMPLATE = (  
2     "Solve the following math word problem. "  
3     "Show brief reasoning and end with the final numeric answer  
4     "after '####'.\n\n"  
5     "Question: {question}\nAnswer:"  
6 )
```

Listing 2. *Prompt de inferência implementado (sistema/node/inference.py).*

Os experimentos preliminares foram executados em modo de simulação — no qual o comportamento de cada perfil é gerado a partir do *Ground Truth* e a latência de cada nó é amostrada de uma distribuição uniforme, não correspondendo a tempo real de inferência — com 20 rodadas por cenário, fator de inércia $\alpha = 0,3$, reputação inicial 0,5, probabilidade de acerto do nó honesto de 0,9, semente 42 e tarefas aritméticas da amostra *offline* do GSM8K avaliadas por correspondência exata da resposta final (as tarefas ilustrativas descritas na Seção 4 não foram empregadas nesta etapa). Foram cobertos doze cenários: três escalas de rede (5, 10 e 20 nós) por três níveis de agentes maliciosos (0%, 25% e 50%), mais uma variante com 50% de nós maliciosos atuando em conluio (todos apontando o mesmo valor incorreto). A Tabela 3 apresenta os resultados; as frações nominais de nós maliciosos são arredondadas ao inteiro, indicado entre parênteses.

Tabela 3. Resultados das execuções preliminares (20 rodadas por cenário, semente 42, modo de simulação).

Rede (nós malic.)	Conluio	Acur. ponderada	Acur. maioria	Rep. honestos	Rep. maliciosos
5 (0)	—	100%	100%	0,87	—
5 (1)	—	100%	100%	0,78	$\approx 0,00$
5 (2)	—	100%	95%	0,84	$\approx 0,00$
5 (2)	sim	100%	95%	0,99	$\approx 0,00$
10 (0)	—	100%	100%	0,94	—
10 (2)	—	100%	100%	0,85	$\approx 0,00$
10 (5)	—	100%	100%	0,91	$\approx 0,00$
10 (5)	sim	95%	0%	0,83	$\approx 0,00$
20 (0)	—	100%	100%	0,93	—
20 (5)	—	100%	100%	0,91	$\approx 0,00$
20 (10)	—	100%	100%	0,92	$\approx 0,00$
20 (10)	sim	95%	0%	0,91	$\approx 0,00$

Sem conluio, os nós maliciosos retornam valores incorretos distintos entre si e não formam bloco majoritário, de modo que os dois mecanismos de consenso atingem 100% de acurácia (as exceções de 95% ocorrem na rede de cinco nós, sensível a um único erro honesto em uma rodada). O efeito do mecanismo de reputação aparece no cenário de conluio com 50% de nós maliciosos: nas redes de 10 e 20 nós, o voto por maioria simples cai para 0% de acurácia, enquanto o consenso ponderado por reputação mantém 95%, pois a reputação dos nós maliciosos converge para valores próximos de zero já nas primeiras rodadas e retira peso de seus votos antes que o bloco em conluio domine a agregação. Cada execução grava os arquivos `per_node.csv`, `rounds.csv` e `summary.json` em `sistema/results/`, permitindo reproduzir os números a partir da semente informada. As principais limitações do estado atual são o uso exclusivo do modo de simulação e a ausência, ainda, da inferência real com o modelo SmoLLM3-3B, do fator de centralidade e da análise estatística com repetições independentes por cenário.

Referências

- Barabási, A.-L. (2016). *Network Science*. Cambridge University Press, Cambridge.
- Blockchain-based distributed AI models: Trust in AI model sharing (2024). *International Journal of Science and Research Archive*.
- Bonawitz, K. et al. (2019). Towards federated learning at scale: System design. In *Proceedings of Machine Learning and Systems*.

- Burns, B., Beda, J., and Hightower, K. (2022). *Kubernetes: Up and Running*. O'Reilly Media, Sebastopol, 3 edition.
- Castro, M. and Liskov, B. (1999). Practical Byzantine fault tolerance. In *Proceedings of the Third Symposium on Operating Systems Design and Implementation (OSDI)*, pages 173–186, New Orleans. USENIX Association.
- Chen, W., Jia, L., Zhou, Y., and Ren, Q. (2024). Reputation-driven asynchronous federated learning for enhanced trajectory prediction with blockchain. *arXiv preprint arXiv:2407.19428*.
- Cobbe, K., Kosaraju, V., Bavarian, M., et al. (2021). Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*.
- Coulouris, G., Dollimore, J., Kindberg, T., and Blair, G. (2021). *Distributed Systems: Concepts and Design*. Pearson, Boston, 6 edition.
- Docker Inc. (2026). *Docker Documentation*. Disponível em: <https://docs.docker.com>. Acesso em: 03 jun. 2026.
- Kairouz, P. et al. (2021). Advances and open problems in federated learning. *Foundations and Trends in Machine Learning*, 14(1–2):1–210.
- Kamvar, S., Schlosser, M., and Garcia-Molina, H. (2003). The EigenTrust algorithm for reputation management in P2P networks. In *Proceedings of the 12th International Conference on World Wide Web*.
- Lamport, L., Shostak, R., and Pease, M. (1982). The Byzantine generals problem. *ACM Transactions on Programming Languages and Systems*, 4(3):382–401.
- McMahan, B. et al. (2017). Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*.
- Russell, S. and Norvig, P. (2020). *Artificial Intelligence: A Modern Approach*. Pearson, Hoboken, 4 edition.
- Shi, W., Cao, J., Zhang, Q., Li, Y., and Xu, L. (2016). Edge computing: Vision and challenges. *IEEE Internet of Things Journal*, 3(5):637–646.
- Tanenbaum, A. S. and van Steen, M. (2017). *Distributed Systems*. Maarten van Steen, Amsterdam, 3 edition.
- Wang, B. et al. (2025). A decentralized asynchronous federated learning framework for edge devices. *Future Generation Computer Systems*.
- Wei, W. and Liu, L. (2024). Trustworthy distributed AI systems: Robustness, privacy, and governance. *arXiv preprint arXiv:2402.01096*.